当代人工智能实验课 · 实验一：文本分类

姓名：钟尉 学号：10245501461

GitHub 仓库：（待补充：上传代码后填入仓库 URL）

1. 问题与目标

本实验对英文新闻文本进行 10 类分类。给定带标签训练集与无标签测试集，需完成文本预处理、特征提取、至少两种分类算法的训练与超参数调优，并在验证集上选出最优模型，对测试集输出 `predictions.csv`。代码将托管于 GitHub，本报告开头保留仓库链接占位，上传后补全。

2. 数据与划分

数据集	规模	说明
train_data.csv	7368 条	text + target（0 9），各类约 705 747，基本均衡
test_data_unlabeled.csv	2457 条	仅文本，需输出类别预测

划分策略：随机种子 42，按标签 分层抽样，验证集比例 20%（训练约 5894、验证 1474）。分层保证各类比例与总体一致；测试集不参与调参，仅用最优模型一次性预测。

3. 预处理与 TF-IDF 特征

3.1 文本清洗

原始文本含邮件/新闻头元数据（如 Organization、Lines 等）。实验中用正则去除常见头字段行并规范空白，降低与主题无关的噪声对词袋特征的干扰。

3.2 TF-IDF 向量化

采用 TfidfVectorizer：max_features=20000；ngram_range=(1,2)（unigram+bigram）；min_df=2；sublinear_tf=True；stop_words='english'。得到高维稀疏特征。新闻类别常由少量区分性词/短语决定，稀疏 TF-IDF 与线性分类器匹配良好。

4. 模型与调参

在同一 TF-IDF 特征上比较四类算法，均在验证集上选超参（随机种子 42）：

算法	调参范围	最优 Acc	最优 Macro-F1
MultinomialNB	$\alpha \in \{0.01,0.1,0.5,1.0\}$	0.9213 (α =0.01)	0.9222
LogisticRegression	$C \in \{0.1,1,10,20\}$	0.9417 (C=20)	0.9419
LinearSVC	$C \in \{0.1,1,5,10\}$	0.9444 (C=1.0)	0.9445
MLPClassifier	(100,)/(200,)/(100,50)+ α	0.9403 (h=200)	0.9407

最终选用 LinearSVC(C=1.0)。用全部训练集在同一向量器上重训后，对无标签测试集写出 predictions.csv（2457 行）。

5. 结果与分析

5.1 模型对比与现象解释

验证集上 LinearSVC 略优于逻辑回归与 MLP，显著优于朴素贝叶斯。稀疏高维文本为何线性模型好？类别近似线性可分，决策由特征权重直接构成；参数少、正则清晰，不易像 MLP 那样拟合噪声 n-gram。SVM 间隔最大化对高维噪声较鲁棒。C=1.0 附近最优，C=5/10 时验证集略降，说明过强拟合训练噪声会损害泛化。逻辑回归随 C 增大精度上升，C=20 接近 SVM 但仍低约 0.3 个百分点。MLP 单隐层 200 维约 94.0%，两层 (100,50) 反而略差，体现参数量增大带来的过拟合风险——本任务上深层非线性并非必要。

5.2 最优模型各类表现

LinearSVC(C=1.0) 验证集 overall accuracy 94.44%，macro-F1 94.45%。类别 5/4/9/8/6 表现最好（F1 多在 0.97+，类 5 近乎完美）；类 2（F1≈0.86）与类 7（F1≈0.88）相对较弱。混淆矩阵显示 类 2 与类 7 相互误分最多（2→7 计 8 例，7→2 计 12 例），提示主题词重叠或文体相近；其余类对角占优。

5.3 实验图表

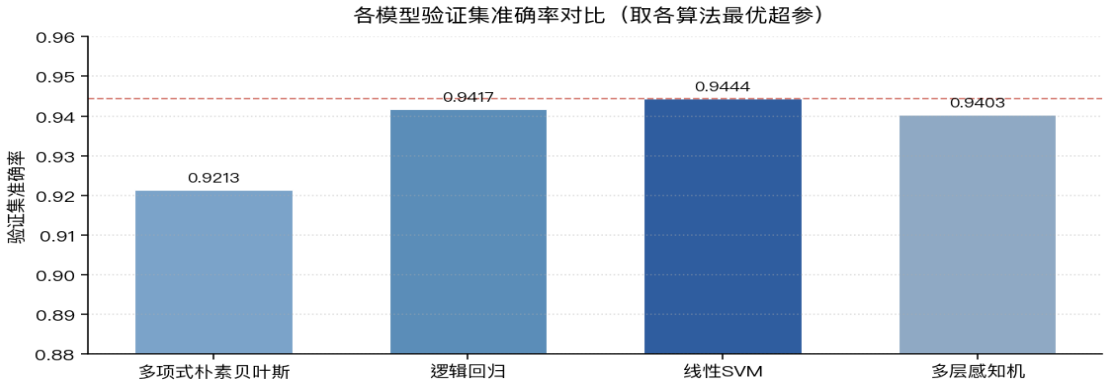


图1 各模型验证集准确率对比（取各算法最优超参）

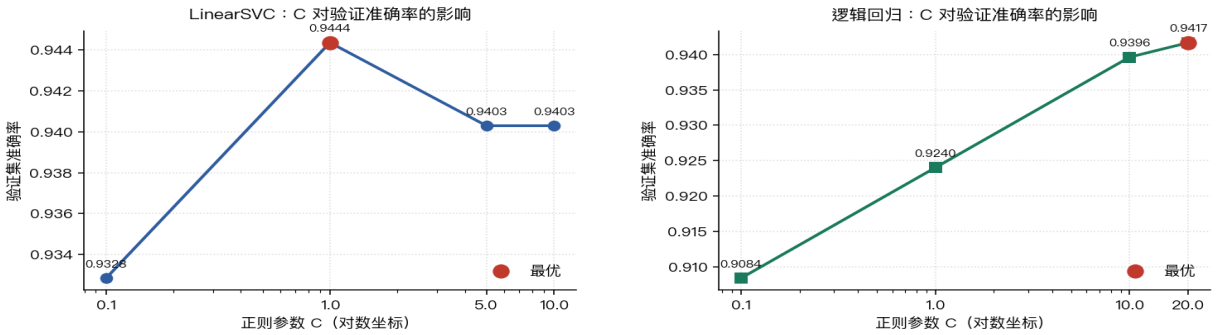


图2 LinearSVC 的 C 曲线（左）与逻辑回归的 C 曲线（右）

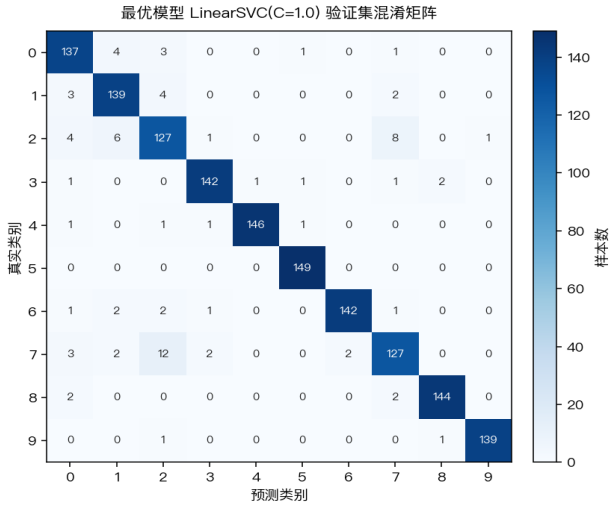


图3 最优模型 LinearSVC(C=1.0) 验证集混淆矩阵

6. 误差分析与思考题

误差原因：(1) 近类主题共享术语，bigram 仍不足；(2) 清洗后仍可能残留签名/引用；(3) TF-IDF 忽略深层语义与篇章结构。思考题：① 线性模型常优于复杂 MLP——高维稀疏、近似线性可分，MLP 易过拟合；② 稀疏特征下线性模型与稀疏矩阵乘高效，正则可抑制无关维；③ 应在验证集上选参，分层划分更公平，过大 C/过深网络未必提升泛化。

7. 结论与局限

本实验完成清洗 + TF-IDF(1　2 gram) + 多模型对比，最终 LinearSVC(C=1.0) 验证准确率约 94.4%，并生成测试集预测。局限：未用预训练语言模型；近类（2 与 7）仍易混；未做交叉验证。后续可尝试字符 n-gram、特征选择、集成或小型 Transformer 微调，并深入近类错误案例。

实验环境：Python / scikit-learn；随机种子 42。图表见 outputs/，预测见 predictions.csv。